Trabajo 4
SR colaborativo

SR
Sistemas Recomendadores

Official Master's Degree in Artificial Intelligence,
Pattern Recognition and Digital Imaging
MIARFID

SR colaborativo

Buscar usuarios similares al usuario actual (vecinos)

Se recomiendan ítems que les han gustado a los vecinos

Para la búsqueda de vecinos se utilizará el coeficiente de correlación de Pearson

Búsqueda de vecinos

Vecinos

Para buscar vecinos se podría	• Usar las preferencias de los usuarios • Usar los ítems puntuados por los usuarios (histórico)
Pero, hay más de 27000 películas, por lo que, si se usan ítems, las matrices serían muy grandes y habría mucho sparsity	• Se van a buscar vecinos por preferencias • Un vecino será aquel cuyas preferencias se parezcan más a las del usuario

Preferencias

Para la búsqueda de vecinos nos interesa que el vector de preferencias tenga la mayor parte de las posiciones rellenas

De esta forma, una posición a 0 representa que el usuario no está interesado en el género, y no, que no la ha rellenado

En el SR basado en contenido usábamos un subconjunto de las preferencias del usuario, aquí las usamos todas

Si no tenemos la mayor parte del vector con datos, puede obtener falsos vecinos

Preferencias del SR

	Usuarios dataset	Usuarios nuevos
Preferencias	Se obtienen las preferencias de las películas puntuadas favorablemente	Se piden las preferencias al usuario cuando se registra: cuantas más, mejor
SR basado en contenido	Filtrar las preferencias y quedarse con las 5-8 de mayor ratio	
SR colaborativo	Todas las preferencias	

Búsqueda de vecinos

Matriz de ratios

Se crea una matriz donde las filas son los usuarios y las columnas las preferencias

Se comparan todos los usuarios con todos

	P1	P2	P3	…	P19
U1					
U2					
…					

¿Qué preferencias usar? Intersección o unión

Intersección

- Buscar vecinos usando solo las preferencias comunes a ambos usuarios

Unión

- Usar las preferencias que uno u otro tenga (rellenando a 0)
- Usar todas las preferencias

	0	1	2	3	…	n
u_1	0	50	34			70
u_2	2	10		70		80

Inters.

	0	1	2	3	…	n
u_1	0	**50**				**70**
u_2	2	**10**				**80**

Unión

	0	1	2	3	…	n
u_1	0	**50**	**34**	**0**		**70**
u_2	2	**10**	**0**	**70**		**80**

¿Qué preferencias usar? Intersección o unión

Se deja libertad para usar la técnica que queráis

Hay que justificar la técnica elegida

Posibilidad

- Dados dos usuarios
- Si tienen más de 10 preferencias comunes, usar la **intersección**
- Si no, usar **unión**

¿Qué preferencias usar? Intersección o unión

Si se usa la unión

- Las preferencias no informadas de un usuario, se rellenan a 0

Si no hay suficientes preferencias con valor puede dar lugar a falsos vecinos

	0	1	2	3	…	n
u_1	0	50	34			70
u_2	2	10		70		80

Unión

	0	1	2	3	…	n
u_1	0	50	34	0		70
u_2	2	10	0	70		80

Obtener vecinos

Usuario del dataset

- Pre-proceso para calcular los vecinos de todos los usuarios del dataset
- Rellenar la lista de vecinos de cada usuario en el perfil de cada usuario

Usuario nuevo

- El usuario se registra
- Se piden las preferencias
- Se calculan los vecinos
- Se almacenan en el perfil del usuario

Perfil de usuario

Identificador de usuario

Modelo de preferencias del usuario

Preferencias completas

Histórico de interacción del usuario con el sistema

Conjunto de ítems del usuario, junto con el ratio dado al ítem

Información interna del SR

Lista de vecinos

Vecinos

Se calculan sus vecinos usando Pearson (todos con todos)

Recordad que la relación de vecindad es asimétrica, pero el coeficiente de correlación es simétrico

Obtener vecinos

Los vecinos serán aquellos cuyo coeficiente de correlación entre sus preferencias sea mayor	
Número de vecinos	• Los N vecinos de mayor ratio • Los vecinos que superen un umbral • No más de 40-50

Correlación de Pearson

La similitud se suele calcular con el coeficiente de correlación de **Pearson**

- Se usa Pearson por ser capaz de calcular similitudes y diferencias
- Independiente de la escala de calificación

Expresión numérica del **grado de relación existente** entre dos vectores

Para cada usuario, se obtiene el **coeficiente de correlación de Pearson** (**r**) entre el usuario **u** y cada uno de los usuarios del sistema (**u'**)

$$r_{u\,u'} = \frac{Cov(vu, vu')}{\sqrt{Var(vu) \cdot Var(vu')}}$$

Correlación de Pearson

$r == 1$	• Correlación positiva perfecta • Dependencia total directa entre los dos vectores: cuando uno de ellos aumenta, el otro también lo hace en proporción constante
$0 < r < 1$	• Correlación positiva • A mayor valor, mayor correlación
$r == 0$	• No existe relación lineal
$-1 < r < 0$	• Correlación negativa
$r == -1$	• Correlación negativa perfecta • Dependencia total inversa entre los dos vectores: cuando uno de ellos aumenta, el otro disminuye en proporción constante

Obtener vecinos

Rellenar los vecinos en el perfil de usuario

Número de vecinos del usuario

Para cada vecino

Variable, depende del usuario

Identificador

Grado de afinidad con el vecino (valor entre 0 y 100)

$$V_u = \{(u', ra_{u'}) \,/\, u' \in U,\ ra_{u'} \in [0..100]\}$$

u es el usuario para el que se solicita la recomendación

$ra_{u'}$, es el ratio de afinidad entre **u** y **u'**. Puede ser un valor entre 0..100 o en el rango que se desee

Proceso de obtención de vecinos

- Crear una matriz con las preferencias de los usuarios del sistema
- Cada fila es un usuario
  Cada columna es una preferencia (tener en cuenta unión/intersección)
- Para cada par de usuarios u y u’, calcular Pearson
- Repetir el proceso para todos los usuarios
- Seleccionar los vecinos con mayor afinidad (valores más cercanos a 1)

Obtener la lista de ítems recomendados

Obtener los ítems recomendados

Para cada vecino

- Obtener los ítems del histórico del vecino puntuados **favorablemente**
  - Decidir que significa “favorablemente”
  - Eliminar los ítems repetidos (más de un usuario tiene el ítem en el histórico)
    - Combinar los ratios de los ítems repetidos (por ejemplo, usar la media de los ratios, ponderada con la afinidad con el vecino y teniendo en cuenta nº de repeticiones)
- Calcular el ratio de interés del ítem para el usuario
- Eliminar de la lista los ítems ya vistos por el usuario (están en su histórico)

Obtener los ítems recomendados

El ratio de interés del ítem para **u** puede depender de

- Si el ítem está repetido en más de un vecino
- Ratio de afinidad con el vecino
- Puntuación del vecino al ítem

Ejemplo: ratio de interés del usuario u en el ítem i

Sea $u'_j \in Vu$

Sea $ra_{u'}$ el ratio de afinidad del usuario u con su vecino u'

Sea ru'_i el ratio que dio el usuario u' al ítem i

El ratio predicho del ítem i para el usuario u, se podría calcular como:

$$ru_i = \frac{\sum_{u' \in V_u, i \in I_{u'}} ra_{u'} . ru'_i}{\sum_{u' \in V_u, i \in I_{u'}} |ra_{u'}|}$$

Obtener los ítems recomendados

Una vez se obtiene la lista de ítems de los vecinos

- Se ordena por ratio
- Se muestran N ítems en la interfaz
- Proceso similar al SRBC

Proceso de recomendación

Usuario del dataset o usuario ya registrado

Un usuario solicita la recomendación (ya tiene calculados los vecinos)

Se le muestra la recomendación obtenida

Usuario nuevo

Registrar al usuario

- Se obtienen las preferencias
- Se calculan sus vecinos

Proceso de recomendación

- Se le muestra la recomendación obtenida