Trabajo 7
Evaluación del SR

SR
Sistemas Recomendadores

Official Master's Degree in Artificial Intelligence,
Pattern Recognition and Digital Imaging
MIARFID

Objetivos

Evaluar el funcionamiento del recomendador

- Comprobar el funcionamiento de cada técnica
- Comparar cada técnica entre si

Recomendación para un único usuario

- Solo para usuarios del dataset
- Seleccionar 20 usuarios aleatoriamente
- Los mismos usuarios se usarán para todas las métricas

Fichero del dataset: ratings.csv o ratings_small.csv

Puntuaciones de usuarios dadas a las películas

- No todos los usuarios tienen puntuados todos los ítems
- Cuidado!! Al haber eliminado películas del fichero, puede que las películas puntuadas no existan
- Contienen:
  - Identificador de usuario
  - Identificador de la película
  - Ratio (**valor entre 0.5 y 5**)

Training set: 70% Test set: 30%

Listas de ítems

Precisión, recall, F1 score y nDCG

- Listas de ítems relevantes: lista de ítems recomendados relevantes por encima de **umbral**$_{\textbf{recomendados}}$
- Lista de ítems de test relevantes por encima de **umbral**$_{\textbf{test}}$

MAE

- Listas de ítems recomendados (todos)
- Lista de ítems de test (todos)
- Usar la **intersección** de las listas

Lista de ítems para MAE: intersección

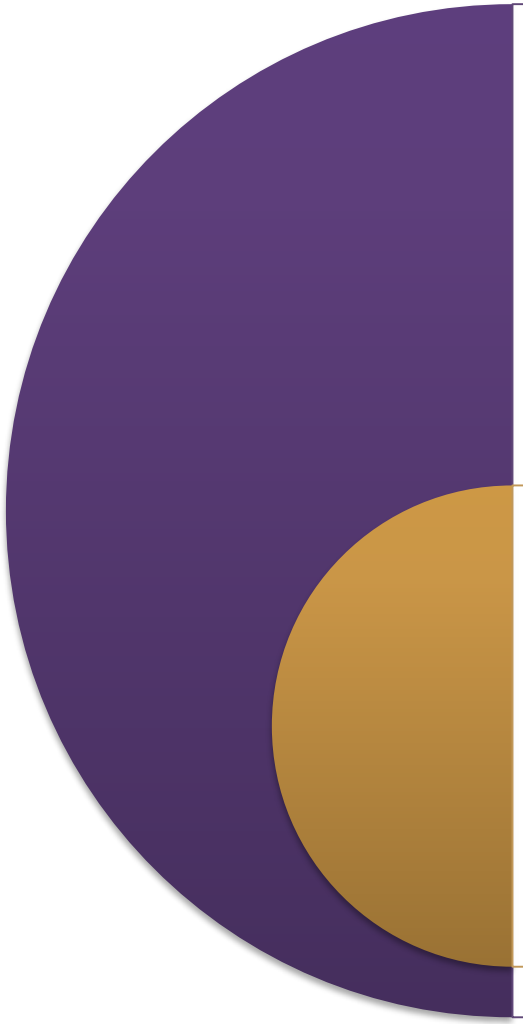

Lista de ítems recomendados	• Todos los ítems recomendados

Para cada uno de los ítems recomendados	• Buscar si el ítem lo ha puntuado el usuario (fichero de test)
	  • Si el ítem lo ha puntuado, usar el ítem
	  • Si no lo ha puntuado, eliminar el ítem de la comparación

Métricas

Precisión, recall y F1

- Mide el acierto de la recomendación (porcentaje de ítems recomendados o no)

MAE

- Mide el acierto de los ratios

nDCG

- Mide orden de las recomendaciones relevantes

Precisión, recall y F1 score

Precisión

Porcentaje de ítems recomendados que son relevantes (de interés) para el usuario

Probabilidad de que un elemento seleccionado sea relevante

Recall

Porcentaje de ítems relevantes para el usuario que son recomendados

Probabilidad de seleccionar un elemento relevante

F1 score

Balance entre precisión y recall

Media armónica de ambos valores

Un mejor F1 score indica un mejor balance entre precisión y recall

Mayor F1, mejor recomendación

$$Precision = \frac{|Recomendados \cap Relevantes|}{|Recomendados|}$$

$$Recall = \frac{|Recomendados \cap Relevantes|}{|Relevantes|}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Precisión, recall y F1 score: gráficas

Ejes

- X: usuarios
- Y: valor de precisión, recall y f1

Gráfica 1: RS basado en contenido

- Línea para precisión
- Línea para recall
- Línea para F1

Gráfica 2: RS colaborativo

- Línea para precisión
- Línea para recall
- Línea para F1

Gráfica 3: RS híbrido

- Línea para precisión
- Línea para recall
- Línea para F1

Precisión, recall y F1 score: gráficas

Gráfica 4: Precisión

- Línea para SR BC
- Línea para SR Col
- Línea para híbrido

Gráfica 5: Recall

- Línea para SR BC
- Línea para SR Col
- Línea para híbrido

Gráfica 6: F1

- Línea para SR BC
- Línea para SR Col
- Línea para híbrido

Precisión, recall y F1 score

Comprobar como funciona cada técnica

Comparar las técnicas entre sí

$$MAE = \frac{\sum_{i=1}^{N} | p_i - r_i |}{N}$$

p: ratio del recomendador

r: ratio del usuario

N: nº ítems

MAE

Error absoluto medio MAE

- Media de la diferencia entre el ratio predicho por el recomendador y el ratio dado por el usuario
- Se usan valores absolutos porque solo interesan las diferencias, sean positivas o negativas
- Cuanto menor es el MAE, mejor recomendación (ideal MAE=0)

Gráfica

- Ejes
  - X usuario
  - Y valor de MAE
- Una línea para cada recomendador

Conclusiones

- Comprobar como funciona cada técnica
- Comparar las técnicas entre sí

Normalized discounted cumulative gain nDCG

Discounted cumulative gain DCG

- Ganancia acumulada descontada
- Penaliza los elementos que aparecen más abajo en la lista
  - Un ítem relevante que aparece abajo en la lista, es una mala recomendación
- Mayor DCG ⇨ mejor recomendación

$$DCG = \sum_{i=1}^{n} \frac{score_i}{log_2(i+1)}$$

Normalized discounted cumulative gain nDCG

- Ganancia acumulada descontada normalizada
- Se ordena la lista de ítems recomendados por relevancia y se calcula su DGC (IDGC): **DGC de test**
- **Valor entre 0 y 1.** Cuanto más se acerca nDCG a 1 ⇨ mejor es la recomendación

$$nDCG = \frac{DCG}{IDCG_n}$$

Normalized discounted cumulative gain nDCG

Usar nDCG para comparar la lista de ítems del usuario con los de test

- Seleccionar de la lista de recomendados los ítems que superan un $umbral_{rec}$
- Seleccionar de la lista de test los ítems superan un $umbral_{test}$
- Asignar un score a la lista de test (definido como queráis)
- Para cada ítem en la lista de recomendados
  - Si el ítem aparece en la lista de test, asignarle el score de test
  - Si no aparece, asignar el score 0
- Calcular $DCG_{recomendados}$ y DCG_{test} (ideal)
- Compararlos usando nDCG

Ejemplo

Rec	Ratio
Ítem 1	0.92
Ítem 2	0.85
Ítem 3	0.8
Ítem 4	0.6
Ítem 5	0.55

Test	Ratio	Score de relevancia
Ítem 2	0.95	4
Ítem 6	0.8	3
Ítem 3	0.65	2
Ítem 7	0.35	1

Rec	Score de relevancia
Ítem 1	0
Ítem 2	4
Ítem 3	2
Ítem 4	0
Ítem 5	0

$$DCG_{Rec} = \frac{0}{log_2(1+1)} + \frac{4}{log_2(1+2)} + \frac{2}{log_2(1+3)} + \frac{0}{log_2(1+4)} + \frac{0}{log_2(1+5)}$$

$$DCG_{Rec} = 0 + 2.52 + 1 + 0 + 0 = 3.52$$

$$DCG_{Test} = \frac{4}{log_2(1+1)} + \frac{3}{log_2(1+2)} + \frac{2}{log_2(1+3)} + \frac{1}{log_2(1+4)}$$

$$DCG_{Test} = 4 + 1.89 + 1 + 0.43 = 7.32$$

$$nDCG = \frac{3.52}{7.32} = 0.48$$

Normalized discounted cumulative gain nDCG

Para cada usuario

- Para cada SR
  - Obtener nDCG

Gráfica

- Ejes
  - X usuario
  - Y valor de nDCG
- Una línea para cada recomendador

Conclusiones

- Comprobar como funciona cada técnica
- Comparar las técnicas entre sí

Medias

Crear una tabla o gráfica con el promedio de las métricas para cada SR (para cada usuario)

Usarla para comparar los recomendadores

SR	Precisión	Recall	F1	MAE	nDCG
BC					
Col					
Híbrido					

Proceso

Para cada usuario

Obtener la lista de ítems de test del usuario (eliminar las películas que no existan)

Para las BRT colaborativa, BRT basada en contenido e híbrida

Obtener la lista de ítems recomendados al usuario con el SR correspondiente

Comparar las listas (listas diferentes según métrica)